Sistem Temu Kembali Informasi

"Model Sistem Temu Kembali Informasi dengan Vector Space Model (VSM)"

TIM Dosen STKI

Buku Penunjang & Literatur

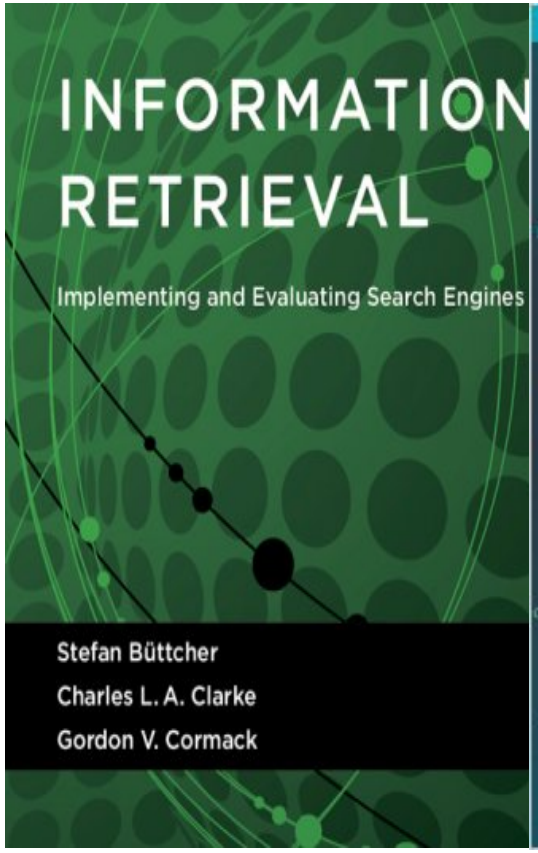

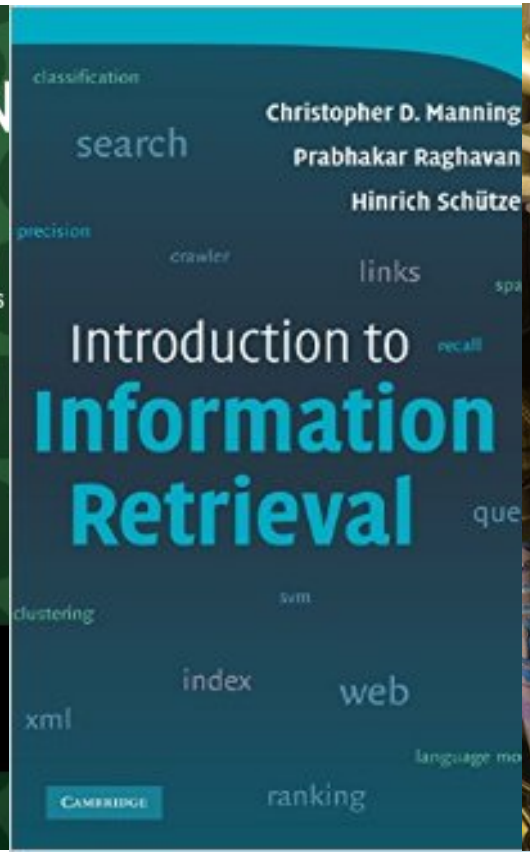

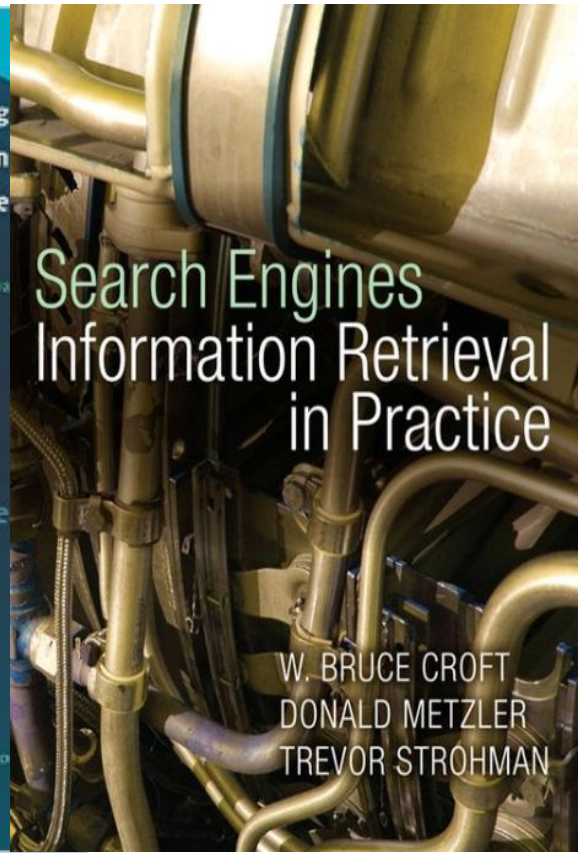

Boolean Model

- Setiap ‘term’ hanya disimbolkan dengan
  - 1 : Muncul dalam dokumen
  - 0 : Tidak muncul dalam dokumen
- Belum merepresentasikan informasi tentang frekuensi kemunculan kata, lokasi kata, atau urutan kemunculan kata.

	a	*aardvark*	*abacus*	*abba*	*able*	...	*zoom*
doc_1	1	0	0	0	0	...	1
doc_2	0	0	0	0	1	...	1
::	::	::	::	::	::	...	0
doc_m	0	0	1	1	0	...	0

Vector Space Model

- Memodelkan ‘term’ kedalam ruang vektor.
- Setiap titik memiliki jarak dan arah di dalam ruang vektor

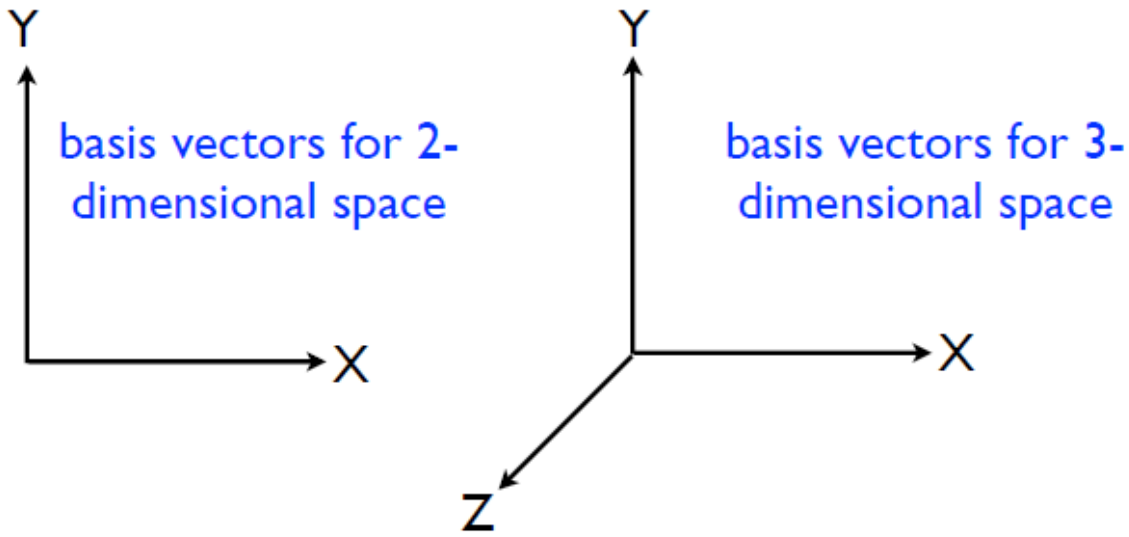

- Setiap kata (term) merupakan satu dimensi dalam ruang vektor.
- Setiap titik merupakan satu dokumen.
- Nilai vektor merepresentasikan jumlah kemunculan kata tertentu dalam dokumen tersebut

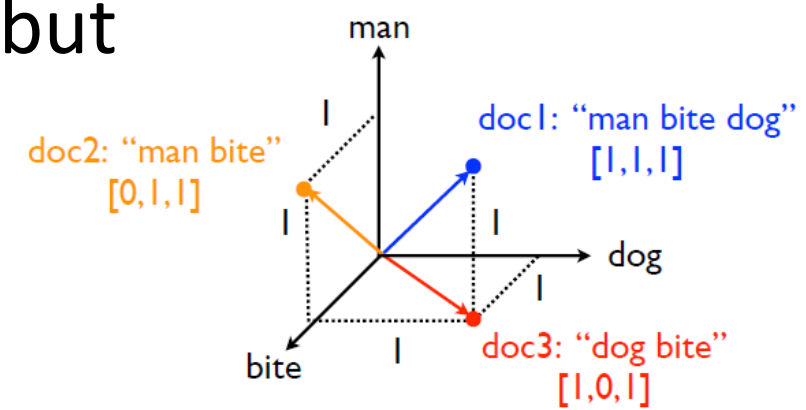

Similarity

- Kemiripan dua vektor bisa dihitung dari seberapa dekat dua titik tersebut dalam ruang vektor.
- Salah satunya dengan menghitung jarak dengan euclidean distance.

$$\begin{aligned} &\text{sim}(\text{doc1}, \text{doc3}) \\ &= -\sqrt{2^2 + 2^2 + 2^2} \\ &= -\sqrt{12} \end{aligned}$$

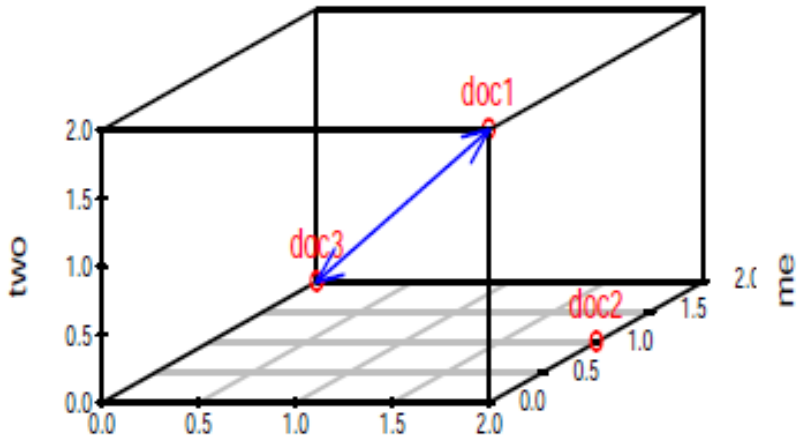

- Memiliki kelemahan karena hanya menghitung kemiripan dari jumlah kemunculan kata.

Point	tea	me	two
doc1	2	0	2
doc2	2	1	0
doc3	0	2	0
doc4	5	0	7

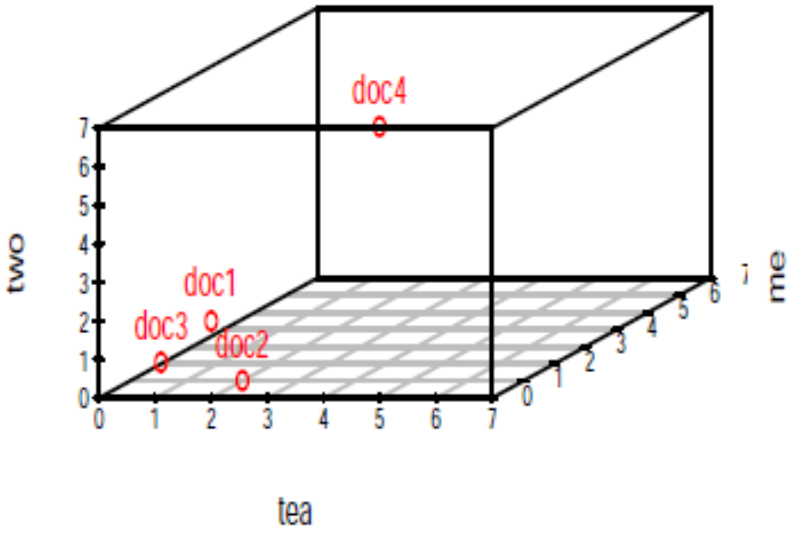

Angular Similarity

- Contoh penghitungan kemiripan lain adalah berdasarkan sudut diantara 2 vektor.

Point	tea	two
doc1	2	2
doc2	2	0
doc4	5	7

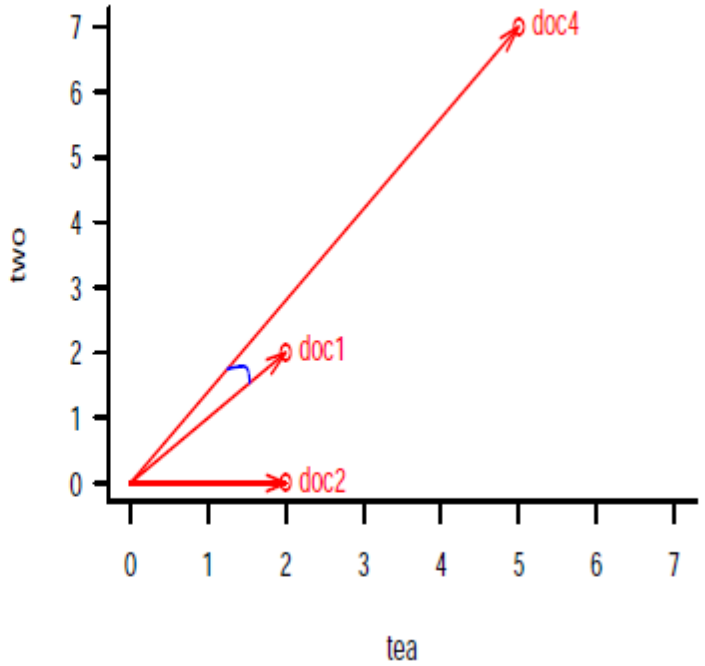

- Contoh perhitungn kemiripan dengan menghitung nilai cos dari sudut diantara dua vektor.

Similarity

$$\cos(\vec{x}, \vec{y}) = \frac{\vec{x} \cdot \vec{y}}{|\vec{x}||\vec{y}|} = \frac{\sum_{i=1}^{n} x_i y_i}{\sqrt{\sum_{i=1}^{n} x_i^2} \sqrt{\sum_{i=1}^{n} y_i^2}}$$

$$\vec{x} = (1, 1, 1, 3, 0) \qquad \vec{y} = (0, 0, 0, 1, 1)$$

$$\vec{x} \cdot \vec{y} = 0 + 0 + 0 + 3 + 0 = 3$$

$$|\vec{x}| = \sqrt{1 + 1 + 1 + 9 + 0} = \sqrt{12}$$

$$|\vec{y}| = \sqrt{0 + 0 + 0 + 1 + 1} = \sqrt{2}$$

$$\cos(\vec{x}, \vec{y}) = \frac{3}{\sqrt{12} \times \sqrt{2}} = \frac{3}{\sqrt{24}} = 0.61$$

Document Ranking

- Misalkan q sebagai vector dari query dan (D1, D2,..., Dn) sebagai dokumen yang akan dibandingkan.
- Hitung nilai kemiripan kosinus q dengan setiap dokumen (D1, D2, ..., Dn)
- Urutkan dokumen berdasarkan nilai kemiripan yang dihasilkan.

Pengertian Vector Space Model (VSM) - (1)

- *Vector Space Model (VSM)* adalah model *Information Retrieval* yang berbasis token untuk memungkinkan *partial matching* dan pemeringkatan dokumen *(pengindexan)*.
- Atau model yang digunakan untuk mengukur kemiripan antara suatu dokumen dengan suatu *query*.
- Dengan prinsip dasar mengubah suatu dokumen menjadi kumpulan token-token.
- *Query* menjadi *vector* token yang berfungsi untuk mencari token yang berhubungan dengan melihat kesamaan *vector* dokumen dan *query* berdasarkan jarak *vector*.

Pengertian Vector Space Model (VSM) - (2)

- *Query* dan dokumen dianggap sebagai vector-vector pada ruang n-dimensi $d_i = (t_{i,1}, t_{i,2}, \ldots, t_{i,k})$, dimana t adalah jumlah dari seluruh *term* yang ada dalam leksikon.

- Leksikon adalah daftar semua term yang ada dalam indeks.

- Untuk setiap *term* tidak hanya dilihat ada atau tidak ada dalam dokumen namun diberi bobot menggunakan *scheme TF* atau *TF-IDF*.

- *TF-IDF* merupakan skema pembobotan yang sering digunakan dalam *Vector Space Model (VSM)* bersama dengan *cosine similarity* untuk menentukan kesamaan antara dua buah dokumen.

Pembobotan Kata (TF-IDF) – (1)

- TF –IDF mempertimbangakan frekuensi kata-kata yang berbeda dalam semua dokumen dan mampu membedakan dokumen. Dalam *Vector Space Model (VSM)*, setiap vector disusun oleh term dan bobot yang mewakili dokumen.

- Kesamaan dokumen dapat dinyatakan dengan sudut atau jarak antara vector, semakin kecil sudut atau jarak berarti semakin mirip dua dokumen tersebut.

Pembobotan Kata (TF-IDF) – (2)

- *TF (Term Frequency)* merupakan frekuensi kemunculan *term (t)* pada dokumen (d).
- *DF (Document Frequency)* merupakan banyaknya dokumen dimana suatu *term (t)* muncul. Atau sebuah dokumen yang mengandung *term (t)*.
- *IDF (Inverse Document Frequency)*

Pembobotan Kata (TF-IDF) – (3)

- Rumus dari *TF-IDF* adalah sebagai berikut :

$$W_{t,d} = TF_{t,d} * IDF_t \qquad (1)$$

Keterangan :

$W_{t,d}$ = bobot dari *t (term)* dalam satu dokumen

$TF_{t,d}$ = frekuensi kemunculan *t (term)* dalam dokumen *d*

IDF_t = *Inverse document frequency*, dimana

$$IDF_t = \log\left(\frac{N}{n_t}\right) \qquad (2)$$

Keterangan :

N = jumlah semua dokumen

n_t = jumlah dokumen yang mengandung *term t*

Perankingan

- Perangkingan dilakukan untuk mengukur kemiripan antara *vector query* dan *vector document* yang akan dibandingkan.

- Salah satu metode yang biasa digunakan dalam perhitungan kemiripan adalah pengukuran *cosine*, yang menentukan sudut antara *vector document* dan *vector query* yang didefinisikan sebagai :

$$Similarity\ (\vec{d_j}, \vec{q}) = \frac{\vec{d_j} . \vec{q}}{|\vec{d_j}| . |\ \vec{q}|} = \frac{\sum_{i=1}^{t}(w_{ij} . w_{iq})}{\sqrt{\sum_{i=1}^{t} w^2{}_{ij} \cdot \sum_{i=1}^{t} w^2{}_{iq}}} \qquad (3)$$

- Dimana, $w_{q,t}$ adalah bobot dari *term (t)*, penyebut dalam persamaan ini disebut faktor normalisasi yang berfungsi untuk menghilangkan pengaruh panjang dokumen.

- Panjang dokumen cenderung memiliki nilai yang lebih besar karena memiliki frekuensi kemunculan kata yang besar pula.

Cosine Similarity – (1)

- Fungsi *similarity* adalah fungsi yang menerima dua buah objek dan mengembalikan nilai kemiripan (*similarity*) antara kedua objek tersebut berupa bilangan riil.

- Umumnya, nilai yang dihasilkan oleh fungsi *similarity* berkisar pada interval [0…1]. Namun, ada juga yang menghasilkan nilai yang berada diluar interval tersebut. Maka untuk memetakannya dapat dilakukan normalisasi.

- *Cosine similarity* adalah perhitungan kesamaan antara dua *vector* n dimensi dengan mencari kosinus dari sudut diantara keduanya dan sering digunakan untuk membandingkan dokumen dalam *text mining*.

Cosine Similarity – (2)

- Berikut rumus Cosine Similarity :

$$Similarity\ (x,y) = \cos(\theta) = \frac{x.y}{\|x\|\|y\|} \qquad (4)$$

Dimana :

x.y : *vector dot product* dari x dan y, dihitung dengan $\sum_{k=1}^{n} x_k y_k$ (5)

$\|x\|$: panjang vektor x, dihitung dengan $\sum_{k=1}^{n} x_k^2$ (6)

$\|y\|$: panjang vektor y, dihitung dengan $\sum_{k=1}^{n} y_k^2$ (7)

Cosine Similarity – (3)

- Semakin besar hasil fungsi similarity, maka kedua objek yang dievaluasi dianggap semakin mirip. Sebaliknya, jika semakin kecil hasil fungsi similarity, maka kedua objek tersebut dianggap semakin berbeda.

- Pada fungsi yang menghasilkan nilai pada jangkauan [0…1], nilai 1 melambangkan kedua objek persis sama, sedangkan nilai 0 melambangkan kedua objek sama sekali berbeda.

Contoh Perhitungan - (1)

Data yang digunakan dalam penelitian ini terdiri dari 12 hama dan 11 penyakit tanaman padi dengan total jumlah gejala sebanyak 48 dalam 3 fase tanam. Untuk proses identifikasi *input*, 48 gejala yang ada akan melalui tahap *preprocessing* untuk dihitung kemiripan dengan *query*. Gejala yang ada direpresentasikan sebagai dokumen dengan kode G1, G2, ..., Gn dan *query user* juga akan dianggap sebagai dokumen pembanding dengan kode Q. Kemudian dilakukan tahap *preprocessing* sebagai berikut :

Menghapus format dan *markup* dalam gejala, kemudian dari tiap gejala dilakukan tokenisasi, yaitu memisahkan tiap kata dalam kalimat, selanjutnya dilakukan *filtering* untuk menghilangkan kata-kata sambung seperti "di", "atau", "seperti" dan lain-lain. Lalu tiap kata akan di-*stemming* dimana akan dihilangkan semua imbuhan yang melekat pada kata, seperti awalan dan akhiran.

Contoh :

G1 : Daun berwarna kuning
G2 : Daun berwarna putih
G3 : Batang berwarna kuning
Q : Daun kuning
Menjadi :
Daun, hijau, kuning, putih, dan batang.

Setelah didapatkan daftar *term,* kemudian dilakukan pembobotan dengan menghitung jumlah frekuensi kemunculan (tf) dan idf dengan rumus $IDF_t = \log\left(\frac{N}{d_f}\right)$, dimana N adalah jumlah keseluruhan gejala dan *query* dan df adalah jumlah gejala dan *query* yang memiliki *term* t.

Contoh Perhitungan – (2)

Tabel 1. Perhitungan tf dan idf

Term	Q	G1	G2	G3	IDF $\left(\log\frac{N}{df}\right)$
Batang	0	0	0	1	$\log\left(\frac{4}{1}\right) = 0.60206$
Daun	1	1	1	0	$\log\left(\frac{4}{3}\right) = 0.12494$
Kuning	1	1	0	1	$\log\left(\frac{4}{3}\right) = 0.12494$
Putih	0	0	1	0	$\log\left(\frac{4}{1}\right) = 0.60206$
Warna	0	1	1	1	$\log\left(\frac{4}{3}\right) = 0.12494$

Kemudian dihitung bobotnya menggunakan rumus TFxIDF :

Tabel 2. Perhitungan pembobotan

Term	Q	G1	G2	G3
Batang	0	0	0	0.60206
Daun	0.12494	0.12494	0.12494	0
Kuning	0.12494	0.12494	0	0.12494
Putih	0	0	0.60206	0
Warna	0	0.12494	0.12494	0.12494

Contoh Perhitungan – (3)

Kemudian dilakukan normalisasi sebagai berikut :

- Menghitung perkalian skalar antar bobot hitung dengan rumus $\sum_{t=1}^{v} W_{q,t} * W_{i,t}$ dan panjang vektor $\sqrt{\sum_{t=1}^{v} w^2{}_{q,t}}$

Tabel 3. Hasil perhitungan panjang vektor

Term	Q	G1	G2	G3
Batang	0	0	0	0.362476
Daun	0.01561	0.01561	0.01561	0
Kuning	0.01561	0.01561	0	0.01561
Putih	0	0	0.362476	0
Warna	0	0.01561	0.01561	0.01561
Jumlah	0.03122	0.04683	0.393696	0.393696
Akar	0.176692	0.216402	0.627452	0.627452

Hasil *cosine* $(\vec{G_i}, \vec{q}) = \frac{\vec{G_i}.\vec{q}}{|\vec{G_i}|.|\vec{q}|} = \frac{\sum_{i=1}^{t}(w_{ij}.w_{iq})}{\sqrt{\sum_{i=1}^{t} w^2{}_{ij}.\sum_{i=1}^{t} w^2{}_{iq}}}$

$$G1 = \frac{0.03122}{0.176692*0.216402} = \frac{0.03122}{0.038237} = 0{,}816497$$

$$G2 = \frac{0.01561}{0.176692*0.627452} = \frac{0.01561}{0.110866} = 0{,}14080$$

$$G3 = \frac{0.01561}{0.176692*0.627452} = \frac{0.01561}{0.110866} = 0{,}14080$$

Dari hasil ini didapatkan bahwa gejala yang paling mewakili maksud dari *input user* yang berupa gejala daun kuning adalah G1 yaitu gejala daun berwarna kuning dengan nilai kemiripan sebesar 0,816497.

Contoh Perhitungan – (4)

Hasil akhir perhitungan kemiripan antar *query* dan gejala akan dianggap sebagai *feedback*. Berikut ini adalah tahap-tahap identifikasi penyakit :

1. Melakukan transformasi biner, hasil perankingan dan penyakit yang ada ditransformasikan menjadi biner, dimana tiap gejala yang berupa hasil identifikasi *input* sebelumnya akan diberi nilai 1 dan yang lain diberi nilai biner 0.

Tabel 5. Contoh transformasi biner untuk *feedback* serta hama wereng coklat dan hama putih palsu

Hama atau penyakit	Gejala			
	Daun warna kuning	Daun berwarna putih	Daun berwarna hijau tua	Batang berwarna kuning
Hama wereng coklat	Ada	Tidak	Tidak	Ada
Hama wereng coklat (t)	1	0	0	1
Hama putih palsu	Tidak	Ada	Tidak	Tidak
Hama putih palsu (t)	0	1	0	0
Feedback	Ya	Tidak	Ya	Ya
Feedback (t)	1	0	1	1

Ket: (t) merupakan hasil tranformasi biner.

Contoh Perhitungan – (5)

Menghitung nilai *cosine similarity* untuk deteksi penyakit.

Contoh :

$X = 1,0,0,1$ (hasil transformasi biner untuk hama wereng coklat)

$Y = 1,0,1,1$ (hasil transformasi biner *feedback*)

$$X.Y = (1 * 1) + (0 * 0) + (0 * 1) + (1 * 1)$$
$$= 1 + 0 + 0 + 1 = 2$$
$$\|x\| = \sqrt{1^2 + 0^2 + 0^2 + 1^2} = \sqrt{2} = 1,41421$$
$$\|y\| = \sqrt{1^2 + 0^2 + 1^2 + 1^2} = \sqrt{3} = 1,73205$$
$$cos(x, y) = \frac{x.y}{\|x\|.\|y\|} = \frac{2}{1,41421.1,73205}$$
$$= \frac{2}{2,44729} = 0,816499$$

Sehingga didapat hasil *similarity* antara hama wereng coklat dan *feedback* adalah sebesar 0,816499.

Kelebihan & Kekurangan Vector Space Model (VSM)

Kelebihan

- Adanya peringkat pengambilan informasi
- Menampilkan referensi yang sesuai kebutuhan
- Penyocokan secara *partial*

Kekurangan

- Menganggap informasi adalah independen
- Bobot permasalahan (istilah) tidak lagi diperlukan

Kuis (Latihan Soal)

- Hitung nilai kemiripan antara ***Query*** dengan ***Dokumen*** kemudian tentukan hasilnya, jika menggunakan Rumus ***Cosinus Similarity***:
  - *Dokumen 1* = Daun bewarna coklat
  - *Dokumen 2* = Bunga bewarna hijau
  - *Dokumen 3* = Rumput bewarna hijau
  - *Query* = Daun hijau

Rumus Cosinus Similarity : $$\cos(\Theta_{ij}) = \frac{\sum_k (d_{ik} d_{jk})}{\sqrt{\sum_k d_{ik}^2} \sqrt{\sum_k d_{jk}^2}}$$

Thanks!

Any questions ?